

## Аннотация

Алгоритмы нейрокомпьютерных интерфейсов решают задачу преобразования сигналов нейронов головного мозга в команды исполняющей системы. В данной работе исследуются механизмы регуляции движения конечностей нейронами головного мозга. Сложность данной задачи заключается в избыточной размерности сигнала. Высокая размерность признакового пространства сигналов приводит к неустойчивости модели машинного обучения. Задачей данной работы является снижение размерности входных данных алгоритма через построение удобного признакового пространства.

Сигнал высокой размерности предлагается аппроксимировать локальной моделью, что существенно уменьшает размерность пространства параметров. В дальнейшем, пространство параметров локальной модели используется в качестве признакового пространства. Таким образом, результирующая модель становится проще и устойчивее. При решении задачи используются данные электрокортикограмм, собранные на основе исследований активности нейронов головного мозга обезьян. В результате проведенных исследований было получено несколько локальных моделей, сокращающих размерность пространства признаков в  $N$  раз и упрощающих вычисления результирующей модели.

## Содержание

1. Аннотация	2
2. Введение	4
3. Постановка задачи	6
3.1. Данные . . . . .	6
3.2. Задача . . . . .	7
3.3. Метрики качества . . . . .	8
4. Исследование локальных моделей	9
4.1. Решения без использования локальных моделей . . . . .	9
4.1.1. Регрессия над сырыми данными . . . . .	9
4.1.2. PLS регрессия над обработанными данными . . . . .	9
4.1.3. Результаты . . . . .	10
4.2. Пространственные локальные модели . . . . .	10
4.2.1. Гипотеза нормального распределения сигнала среди каналов . . . .	12
4.2.2. Гипотеза гамма-распределения . . . . .	13
4.2.3. Обоснование результатов . . . . .	13
4.3. Временные локальные модели . . . . .	16
4.3.1. Авторегрессия на новых признаках . . . . .	16
5. Результаты	18
6. Заключение	19

## Введение

В последнее время большое количество работ посвящено методам считывания мозговой активности и декодирования информации [?, ?, ?, ?, ?, ?, ?]. Основным применением данных методов являются нейрокомпьютерные интерфейсы (Brain Computer Interface), которые позволяют восстановить мобильность людей с нарушениями двигательных функций. Алгоритм BCI транслирует сигналы нейронов головного мозга в команды для исполняющей системы [?]. Это дает возможность регулировать движение роботизированной конечности в соответствии с механизмами нервной регуляции. [?].

В этой работе используются данные сигналов мозга, полученные инвазивным методом электрокортикографии (subdural ECoG) [?]. Сложность задачи декодирования сигналов мозга заключается в избыточной размерности пространства признаков: модель прогнозирования намерений является неустойчивой. Для построения устойчивой модели необходимо построить удобное признаковое пространство.

Исследование состоит в восстановлении зависимостей между сигналами ECoG и движениями конечностей. Для точного предсказания траектории движения в трехмерном пространстве требуется снизить размерность исходного признакового пространства. Также предлагается исследовать возможность построения предсказательных моделей на сырых данных.

Стандартные подходы для установления зависимостей между электрокортикограммой и координатами конечностей состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала[?, ?] и требуют предварительной обработки данных. Большинство методов в смежных работах исследуют только частотные характеристики[?, ?, ?]. В работах [?, ?] рассматриваются все признаки вне зависимости от их природы. Наиболее распространёнными моделями для предсказания движения являются алгоритмы PLS[?, ?] и PCA[?, ?]. В работе [?] используются алгоритмы, построенные на скрытых марковских моделях. В работах [?, ?] авторы рассматривают различные участки сигнала в виде слов. В работе [?] исследован метод отбора признаков с помощью квадратичного программирования (Quadratic Programming Feature Selection [?]).

В данной работе для моделирования фронта распределения сигнала предлагается использовать локальную структуру сигнала. Движение фронта возбуждения нейронов приближается с помощью локальной модели прогнозирования движений, а в качестве нового признакового описания объектов используются параметры построенной локаль-

ной модели. Полученный метод значительно снижает размерность данных, использует пространственную информацию и сохраняет свойства распространения сигнала. Как следствие, количество параметров конечной модели значительно уменьшается. Получается более простая аппроксимация сигнала высокой размерности и более устойчивая прогностическая модель.

## Постановка задачи

### 3.1 Данные

В эксперименте используются данные с сайта neurotycho.org. Сбор данных производился с использованием методики Multi-Dimensional Recording. Запись сигналов ECoG и траектории движения руки проводилась одновременно. Каждый из экспериментов длился 15 минут, первые 8 минут производилась запись обучающей выборки, оставшиеся 7 минут – запись тестовой выборки. На [рис.2] приведен пример записи ECoG с некоторых каналов.

Исходные данные представляют собой отрезки многомерных временных рядов электрокортикограммы. Запись электрокортикограммы производилась с частотой 1 кГц, запись движения - с частотой 120 Гц. Рассматривалась синхронизация движения двумя методами:

1. каждой координате было сопоставлено значение ECoG, соответствующее временной отметке движения
2. каждой координате было сопоставлено значение ECoG, полученное экспоненциальным сглаживанием значений за последние 0.007 с. 0.007 с - среднее значение временного промежутка между соседними отметками времени координат

Пространство исходных данных имеет размерность  $T \times N$ . Пространство данных, на которых обучается большинство моделей, в частности [?] - результат предобработки исходных данных, оно имеет размерность  $T \times N \times F$ , где  $N$  – число каналов,  $T$  – количество отсчетов времени,  $F$  – дискретный спектр наблюдаемых частот. Тогда матрица значений напряжения  $\mathbf{X} \in \mathbb{R}^{T \times (N \times F)}$ , целевая переменная -  $\mathbf{Y} \in \mathbb{R}^{T \times 3}$ .

Исходные данные представлены в виде массивов:

$$\mathbf{X} = \{x_{ti}\}_{t=1, \dots, T; i=1, \dots, N}; \quad (1)$$

$$\mathbf{Y} = \{y_{ti}\}_{t=1, \dots, T; i=1, 2, 3}; \quad (2)$$

Объектом будем называть вектор  $\mathbf{x}_t \in \mathbb{R}^N$  с измерениями в каждый отрезок времени,  $i = 1, \dots, T$ . Вектор состоит из  $N$  элементов, каждый из которых соответствует каналу.

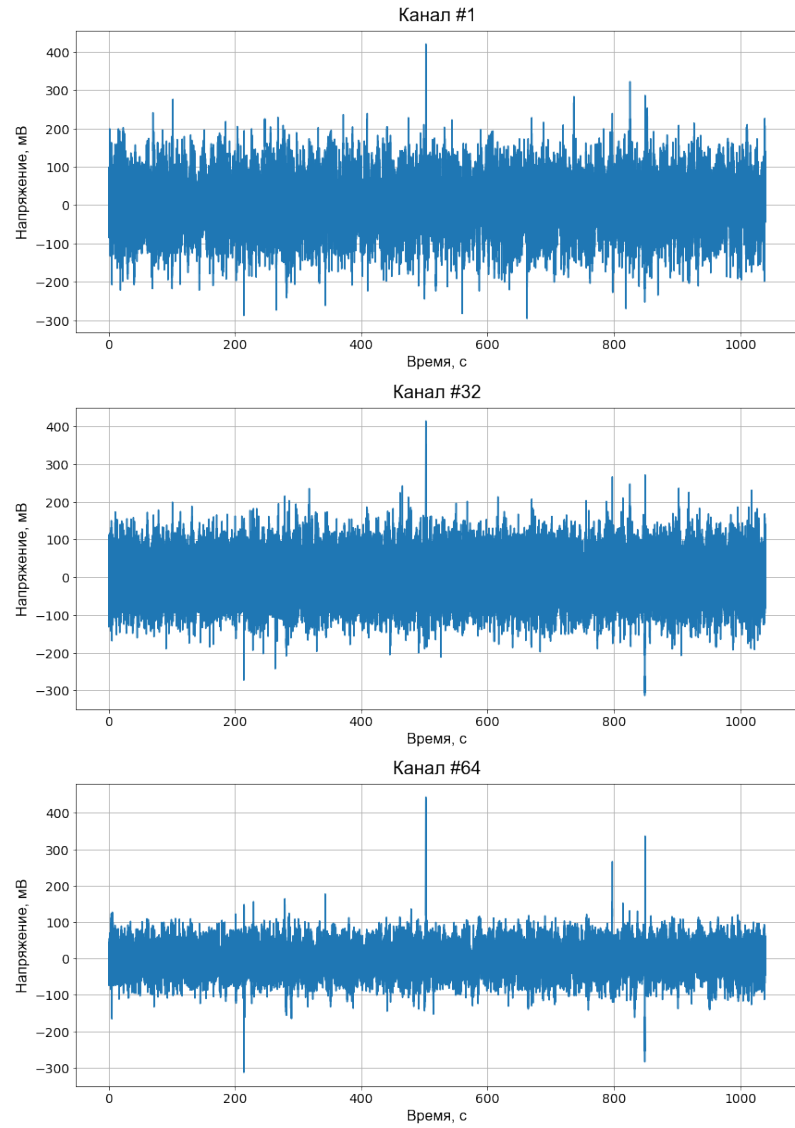


Рис. 1. Изменения значений напряжения на 1, 32 и 64 каналах

Значение  $y_{ti}$  отвечает  $i$ -й координате траектории движения конечности в момент времени  $t$ .

## 3.2 Задача

Необходимо построить информативное признаковое пространство для предсказания траектории движения конечности. Модель прогнозирования  $f : \mathbf{X} \rightarrow \mathbf{Y}$  предлагается искать классе суперпозиции двух моделей:  $f = g \circ h : \mathbf{X} \rightarrow \mathbf{Y}$ . Локальная модель  $g : \mathbf{X} \times \boldsymbol{\theta} \rightarrow \mathbf{X}$  использует локальную пространственную структуру сигнала для аппроксимации перемещения фронта возбуждения.

Модель  $g(\mathbf{X}, \boldsymbol{\theta})$  решает задачу оптимизации параметров  $\boldsymbol{\theta}^i$  для временного ряда  $\mathbf{x}_i$ :

$$\boldsymbol{\theta}^i(\mathbf{X}) = \underset{\boldsymbol{\theta}^i}{\operatorname{argmin}} L(g(\mathbf{x}_i, \boldsymbol{\theta}^i)) \quad (3)$$

или же аппроксимирует  $x_t$   $g(x_t, \boldsymbol{\theta})$ . В таком случае получаем задачу оптимизации

$$\boldsymbol{\theta}^i(\mathbf{X}) = \underset{\boldsymbol{\theta}^i}{\operatorname{argmin}} L(g(\mathbf{x}_t, \boldsymbol{\theta}^i)) \quad (4)$$

Параметры модели  $g(\mathbf{X}, \boldsymbol{\theta}^i)$ ,  $i = 1, \dots, T$  используются как новое признаковое пространство  $\boldsymbol{\theta} \in \mathbb{R}^{T \times d}$ .  $d$  - размерность пространства параметров локальной модели.

Примером модели  $h(\boldsymbol{\theta}, \mathbf{w}) : \boldsymbol{\theta} \rightarrow \mathbf{Y}$  является модель линейной регрессии с параметрами  $\mathbf{w}$ . На этапе применения модели  $h(\boldsymbol{\theta}, \mathbf{w})$  построенное признаковое описание  $\boldsymbol{\theta}$  используется для предсказания траекторий  $\hat{\mathbf{Y}}$ . Параметры  $\mathbf{w}$  модели  $h(\boldsymbol{\theta}, \mathbf{w})$  находятся путем минимизации функции потерь  $L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h)$ :

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (5)$$

В качестве функции потерь можно выбрать, например, квадратичную ошибку:

$$L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h) = \|\mathbf{Y} - \hat{\mathbf{Y}}\|_2^2. \quad (6)$$

Общая постановка задачи:

$$\mathbf{w}, \boldsymbol{\theta} = \underset{\mathbf{w}, \boldsymbol{\theta}}{\operatorname{argmin}} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (7)$$

Цель работы состоит в нахождении оптимальной локальной модели  $g(\mathbf{X}, \boldsymbol{\theta})$  для построения информативного признакового пространства и устойчивой результирующей модели.

### 3.3 Метрики качества

## Исследование локальных моделей

### 4.1 Решения без использования локальных моделей

Перед началом работы были проведены эксперименты, определяющие базисные линии для оценки качества предлагаемых алгоритмов, использующих локальные модели.

#### 4.1.1 Регрессия над сырыми данными

Рассматривается обычная линейная модель  $\mathbf{y} = \mathbf{X}\mathbf{w} + \mathbf{b}$ , где  $\mathbf{X} \in \mathbf{R}^{T \times N}$ ,  $\mathbf{y} \in \mathbf{R}^T$ .

mae	mse	r2-score
26.67	1395.70	-0.32

Таблица 1. Метрики для регрессии над сырыми данными




Рис. 2. Результаты работы линейной регрессии на сырых данных, координата x

#### 4.1.2 PLS регрессия над обработанными данными

Над данными производилась предварительная обработка, состоящая из полосового фильтра, вейвлет-преобразования и шкалограммы. Затем, с помощью алгоритма PLS, по предобработанным данным предсказывалось движение.

Алгоритм дает следующие результаты:

В оригинальной статье также применялся метод отбора признаков QPFS, с помощью которого достигаются следующие значения r2-score: 0.62 для обучающей выборки и



выборка	mae	mse	r2-score
train	1.69	5.38	0.96
test	5.38	472.42	-0.37

Таблица 2. Метрики для алгоритма PLSRegression




Рис. 3. Результаты работы PLSRegression на предобработанных данных, тренировочная выборка

0.48 для тестовой. Эти значения достигаются при отборе 1000 признаков. На [рис. N] представлены графики результатов экспериментов из оригинальной статьи.

### 4.1.3 Результаты

По результатам вычислительного эксперимента можно видеть, что простые модели неустойчивы на большом признаковом пространстве и не определяют зависимостей на сырых исходных данных. Для дальнейшего исследования локальных моделей над исходными данными примем следующие базисные линии для функционала качества. В качестве целевого значения функционала качества рассматривается значение 0.48, в качестве нижнего порогового значения - 0, так как это значение соответствует случайному предсказанию.

## 4.2 Пространственные локальные модели

Для использования пространственной локальной структуры сигнала предлагается обратиться к нейробиологическим представлениям о распространении сигналов головного мозга. Нейроны и связи между ними образуют граф, описывающий возможные пути распространения сигналов. Каждый нейрон соединен с помощью множества отростков с приблизительно 20 тысячами других нейронов. Точно учесть локальную структуру графа при описании сигнала невозможно, так как это потребует большого количества вычислительных ресурсов. В связи с этим предлагается модель локальной аппроксимации формы и перемещения фронта. Активность нейронов представляет собой временные всплески сигналов различной интенсивности, их суперпозицию и распространение. Каждый канал имеет доступ к сигналам некоторого количества нейронов, находящихся

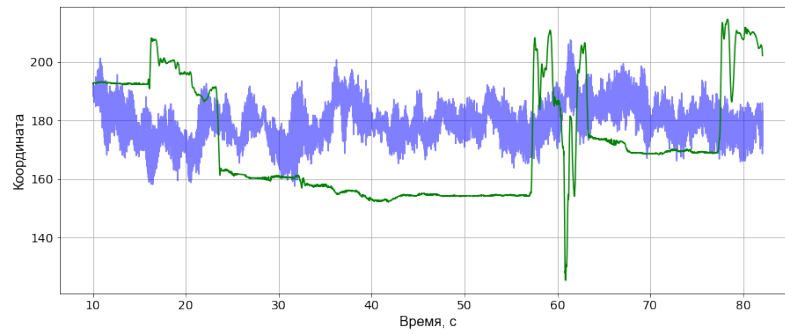


Рис. 4. Результаты работы PLSRegression на предобработанных данных, тестовая выборка

в небольшой области пространства и снимает суммарную интенсивность сигнала.




Рис. 5. Перемещение сигнала среди каналов

На [рис.1] можно заметить, что фронт перемещается по сети в большинстве случаев как единое целое, при этом интенсивность сигнала максимальна в центре множества активных узлов и убывает к периферии. У такой структуры сигнала есть возможное объяснение, основанное на устройстве нейронной сети. Нейрон имеет большое количество небольших отростков - дендритов, основной функцией которых является передача возбуждения к телу нейрона извне, и обычно один аксон, служащий для передачи импульса от тела другим нейронам или мышечной ткани. Получается, что импульсы собираются от периферии к центру каждого нейрона, после чего суммарный импульс, если он достаточно велик, передается по аксону дальше. Таким образом, форма фронта возбуждения приближается с помощью пространственной локальной локальной модели в каждый момент времени. В качестве признакового описания объектов в дальнейшем используются параметры построенной локальной модели. Полученные методы снижают размерность данных, используют пространственную информацию и сохраняют свойства распространения сигнала.

Основываясь на существующем представлении о распространении сигнала по нейронам и его форме выдвигаются следующие гипотезы: в каждый момент времени распределение интенсивности сигнала в пространстве каналов имеет нормальное или гамма-распределение. В обоих случаях распределение понимается двумерным. Соответствие пространства каналов координатному представлению представлено на [рис.5].

Учитывая, что напряжение на каналах может быть как положительным, так и отри-




Рис. 6. Расположение каналов на мозге и их соответствие кординатной сетке

цательным, локальная модель, приближающая сигнал ECoG должна иметь поправку на знак. Следовательно, рассматривается параметр пиковой интенсивности и производить на него поправку. Это позволяет масштабировать результат и определять его знак.

#### 4.2.1 Гипотеза нормального распределения сигнала среди каналов

Математическая постановка

Предположим, что интенсивность сигнала подчиняется модели нормального распределения. Номера каналов заменим на координаты в соответствие с [рис. 5] и рассмотрим двумерное нормальное распределение. Тогда  $\mathbf{x}_t \in \mathcal{N}(\mathbf{m}(t), \sigma(t))$ . Математическое ожидание  $\mathbf{m}(t)$  аппроксимирует положение пика интенсивности в момент времени  $t$ , а ковариационная матрица  $\sigma(t)$  описывает форму фронта. Параметры распределения  $\theta_1 = (\mathbf{m}(t), \sigma(t))$ . Также в качестве параметра добавляем максимальное значение напряжения в момент времени  $t$  в качестве поправки для масштабирования сигнала. Таким образом, новое признаковое пространство -  $\theta = (\mathbf{m}(t), \sigma(t), \text{mathbf{f}}i(t))$

Эксперимент

Результат работы линейной модели над новым признаковыми пространством не превосходит результатов работы аналогичной модели над исходными данными.

mae	mse	r2-score
27.62	1572.93	-0.33

Таблица 3. Метрики для регрессии над сырыми данными

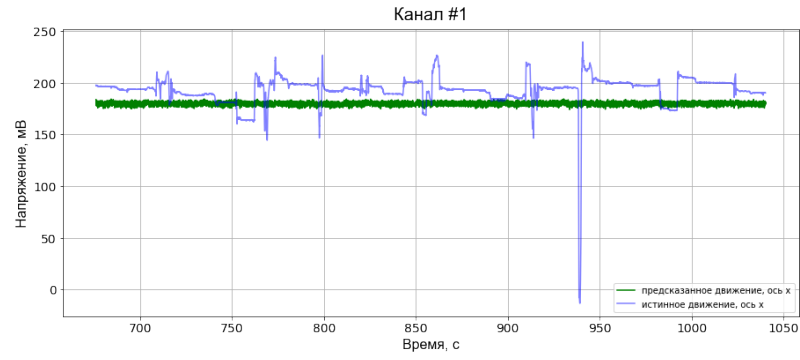


Рис. 7. Результат работы линейной модели над новым признаковым пространством

## 4.2.2 Гипотеза гамма-распределения

Математическая постановка

Если предположить дополнительно, что на распределение интенсивности в пределах группы нейронов влияет направленное распространение сигнала внутри группы, можно выдвинуть гипотезу  $x_{ti} \in \Gamma(k, \theta)$ ,  $i = 1, \dots, N$ , так как гамма-распределение не является симметричным. Параметры распределения  $\theta = \{(k_i, \theta_i)\}_{i=1}^T$ .

Эксперименты

Как и в случае с нормальным распределением, модель не даёт улучшения качества результатов.




Рис. 8. Результат работы линейной модели над новым признаковым пространством

## 4.2.3 Обоснование результатов

Полученные результаты говорят о том, что предположение о возможности предсказать движение посредством параметров распределения сигнала в пространстве является ошибочным.

После сравнения электрокортикограмм, восстановленных с помощью случайного леса над пространством параметров локальной модели, и электрокортикограмм, восста-

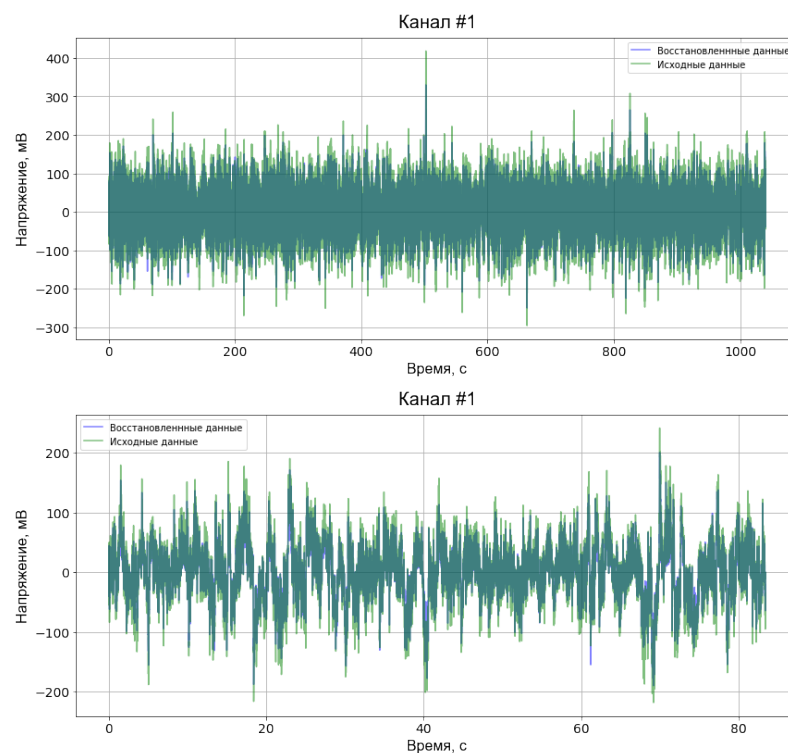


Рис. 9. Восстановление ээг по нормальному распределению, 1 канал

новленных с помощью функций локальных моделей, можно сделать вывод о том, что предложенные локальные модели слишком просты для описания изучаемых сигналов мозга. Существует слабая связь сигналов мозга с параметрами предложенных моделей, однако эти модели недостаточно хорошо приближают сигнал. В результате данные гипотезы отклоняются.

Значения метрик:

mae	mse	r2-score
90.69	22129.04	-0.05

Таблица 4. Метрики для гипотезы нормального распределения

Значения метрик:

mae	mse	r2-score
33.76	1921.38	0.02

Таблица 5. Метрики для гипотезы гамма-распределения

Значения метрик:

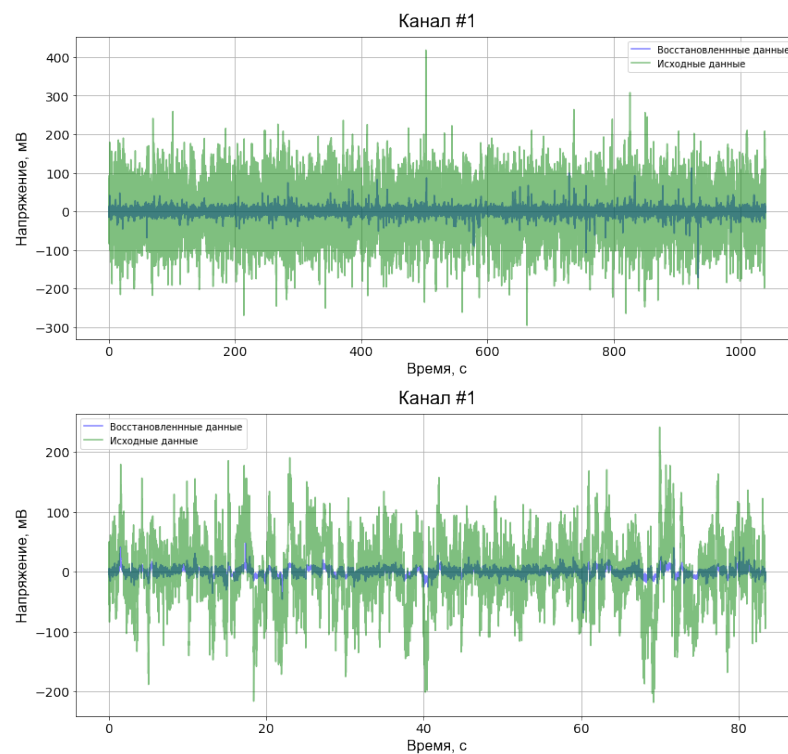


Рис. 10. Восстановление эога по гамма-распределению, 1 канал




Рис. 11. Восстановление эога по параметрам распределений с помощью линейной регрессии, 1 канал




Рис. 12. Восстановление эхог по параметрам распределений с помощью случайного леса, 1 канал

модель	mae	mse	r2-score
Линейная регрессия	34.67	2117.99	0.11
Random forest	31.29	1814.65	0.26

Таблица 6. Метрики для гипотезы нормального распределения

### 4.3 Временные локальные модели

Наиболее широко распространенным примером временной локальной модели для временных рядов является модель авторегрессии:

$$\begin{pmatrix} x_{t+1,i} \\ x_{t,i} \\ \dots \\ x_{T_i,i} \end{pmatrix} \begin{vmatrix} x_{t,i} & \dots & x_{t-d,i} \\ x_{t-1,i} & \dots & x_{t-d-1,i} \\ \dots & \dots & \dots \\ \dots & \dots & \dots \end{vmatrix} \begin{pmatrix} \theta_1^i \\ \theta_2^i \\ \dots \\ \theta_d^i \end{pmatrix}. \quad (8)$$

Обычно данная модель используется для предсказания следующего элемента временного ряда. В данной работе коэффициенты авторегрессии по последним значениям электрокортикограммы будут рассматриваться в качестве нового признакового пространства.

#### 4.3.1 Авторегрессия на новых признаках

Далее предлагается рассмотреть композицию пространственной и временной локальных моделей. В качестве основной модели рассматривается авторегрессия. Для уменьшения размерности признакового пространства из пространственной компоненты извлекаются новые признаки, основанные на агрегированных данных напряжения с каналов. Авторегрессия для сырых данных является приемлемой локальной моделью. На [рис.] представлены графики, позволяющие утверждать, что модель авторегрессии подходит для рассматриваемых данных. На графиках видно, что зависимость  $y(t+1) = f(y(t))$  линейная.




Рис. 13. Lag plot для электрокортикограммы (все каналы)




Рис. 14. Lag plot для координаты  $x$

Генерация признаков

Локальная модель

Результирующая модель

Эксперименты



## Результаты

## Заключение

В результате данной работы построены несколько локальных моделей, дающих приемлемое качество последующих предсказаний движения. Предполагается дальнейшее улучшение этих моделей, а также использование их результатов в качестве baseline для построения более удобного признакового пространства с использованием алгоритмов глубокого обучения.